CKP7500 - SISTEMAS DISTRIBUÍDOS E REDES DE COMUNICAÇÃO

SMD0050 - SISTEMAS DISTRIBUÍDOS - T02

ALGORITMOS DE ELEIÇÃO

SLIDES SÃO BASEADOS NOS SLIDES DO COULORIS E TANENBAUM

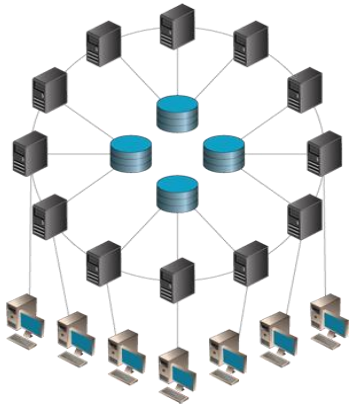

Algoritmos de Eleição

Usados quando há necessidade de um ou mais nós devem agir como coordenador

Coordenar a replicação, difusão, agregação

- Formação de Scartternet em Bluetooth

Iniciar/coordenar um processo de resolução de consenso

- Paxos, RAFT

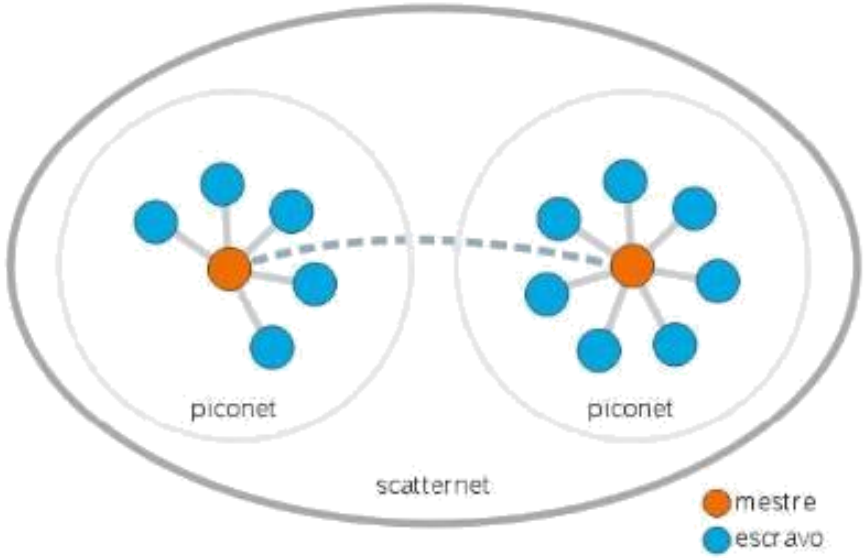

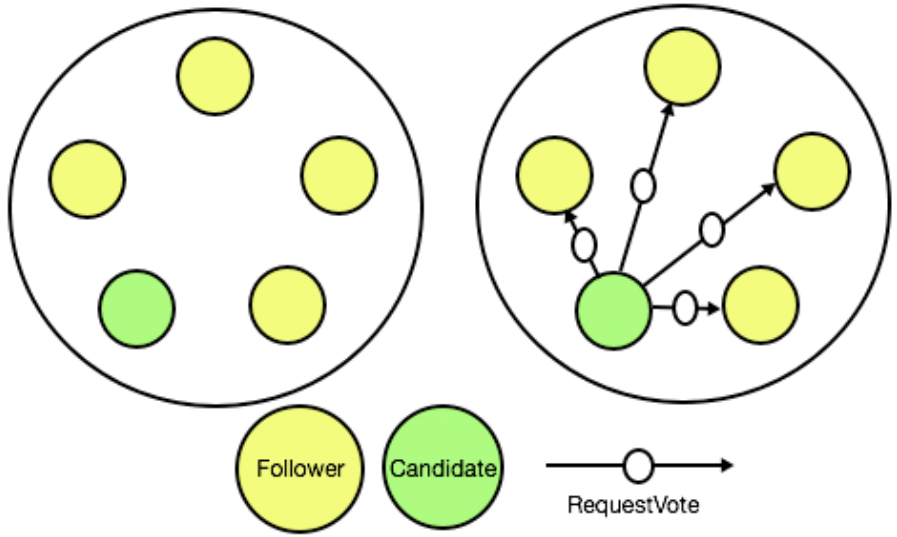

Exemplos de Algoritmos de Eleição

De propósito geral

- Algoritmo do valentão
- Algoritmo de anel

Soluções para ambientes específicos

- Algoritmos para Ad Hoc (Bluetooth Topology Construction)
- Algoritmos para sistemas de grande escala (Blockchain)

Requisitos importantes

Safety - Todos os participantes precisam chegar a um consenso ou serem informados de quem foi o escolhido

Liveness – Em algum momento, deve-se definir o coordenador

Stability – Devem ser evitadas reeleições desnecessárias

Nem sempre é possível saber o número total de processos

- inundação, topologia em anel

Requisitos importantes

A eleição é iniciada como reação a uma detecção de falha do antigo coordenador

Pode haver falha durante a escolha do novo coordenador

Múltiplas eleições podem ocorrer em paralelo mas devem chegar a um mesmo resultado

Tarefa 1- Vamos tentar criar o nosso!

Não vale pescar!

Tarefa 1- Vamos tentar criar o nosso!

Não vale pescar!

Processos podem ser identificados pelo seu IP e PID

Processos tem a lista de IPs de todos os membros

O processo de PID 2 detectou que o coordenador não está mais ativo

Tô pensando em ser o coordenador!

Todas as máquinas ativas são capazes de serem o coordenador

Algoritmo do Valentão (Bully)

Inventado por Garcia-Molina (1982)

Todos nós possuem um identificador

Sistema síncrono com falhas tipo fail-stop*, baseado na difusão de mensagens

É eleito o nó com maior identificador que está ativo

*fail-stop – processo “cai” e isso é detectável por parceiros.

Algoritmo do Valentão

Sempre que um nó qualquer P nota que o coordenador não responde, P inicia uma eleição:

1. P envia uma mensagem ELEIÇÃO a todos os processos de números mais altos;
2. Se nenhum responder (sistema síncrono), P vence a eleição e se torna o coordenador;
3. Se um dos processos de número mais alto responder, ele toma o poder e o trabalho de P está concluído.

Algoritmo do Valentão - Suposições

Sistema Síncrono - Toda mensagem é entregue em Tm unidades de tempo após o seu envio

Todos os processos não falhos respondem a todas as mensagens recebidas em Tp unidades de tempo

Definição de um detector de falhas confiável:

Se um processo não responde em 2Tm+Tp unidades de tempo, ele falhou

Algoritmo do Valentão

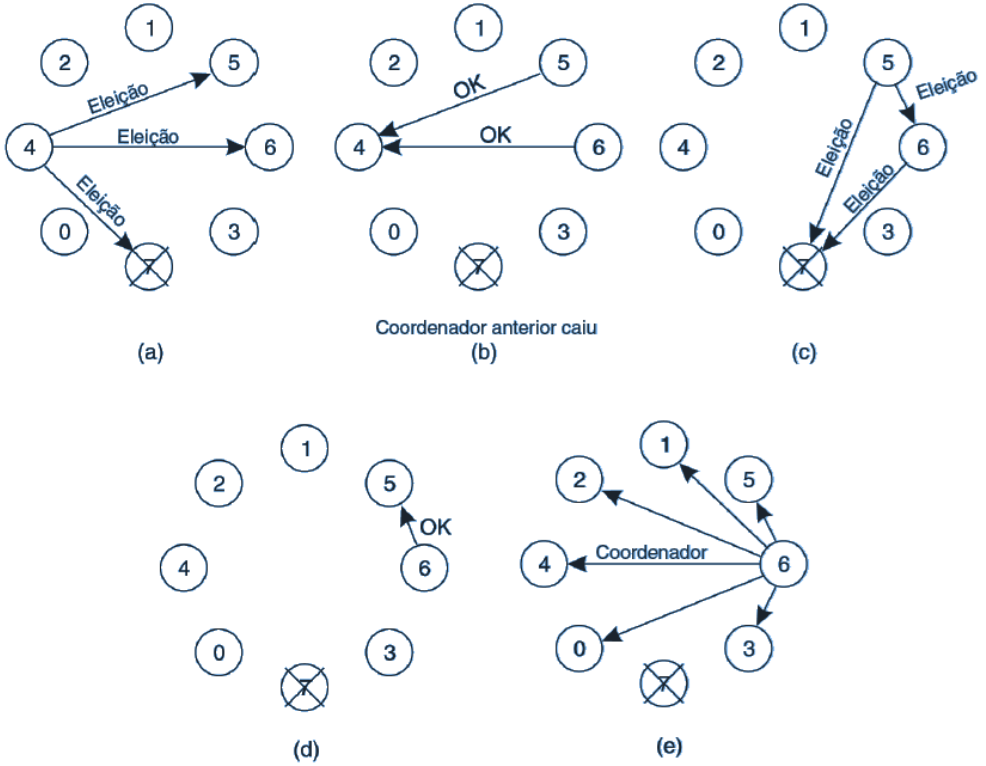

Figura 6.19 *Algoritmo de eleição do valentão. (a) O processo 4 convoca uma eleição. (b) Os processos 5 e 6 respondem e mandam 4 parar. (c) Agora, cada um, 5 e 6, convoca uma eleição. (d) O processo 6 manda 5 parar. (e) O processo 6 vence e informa a todos.*

Vantagens e Desvantagens?

Vídeo de Revisão

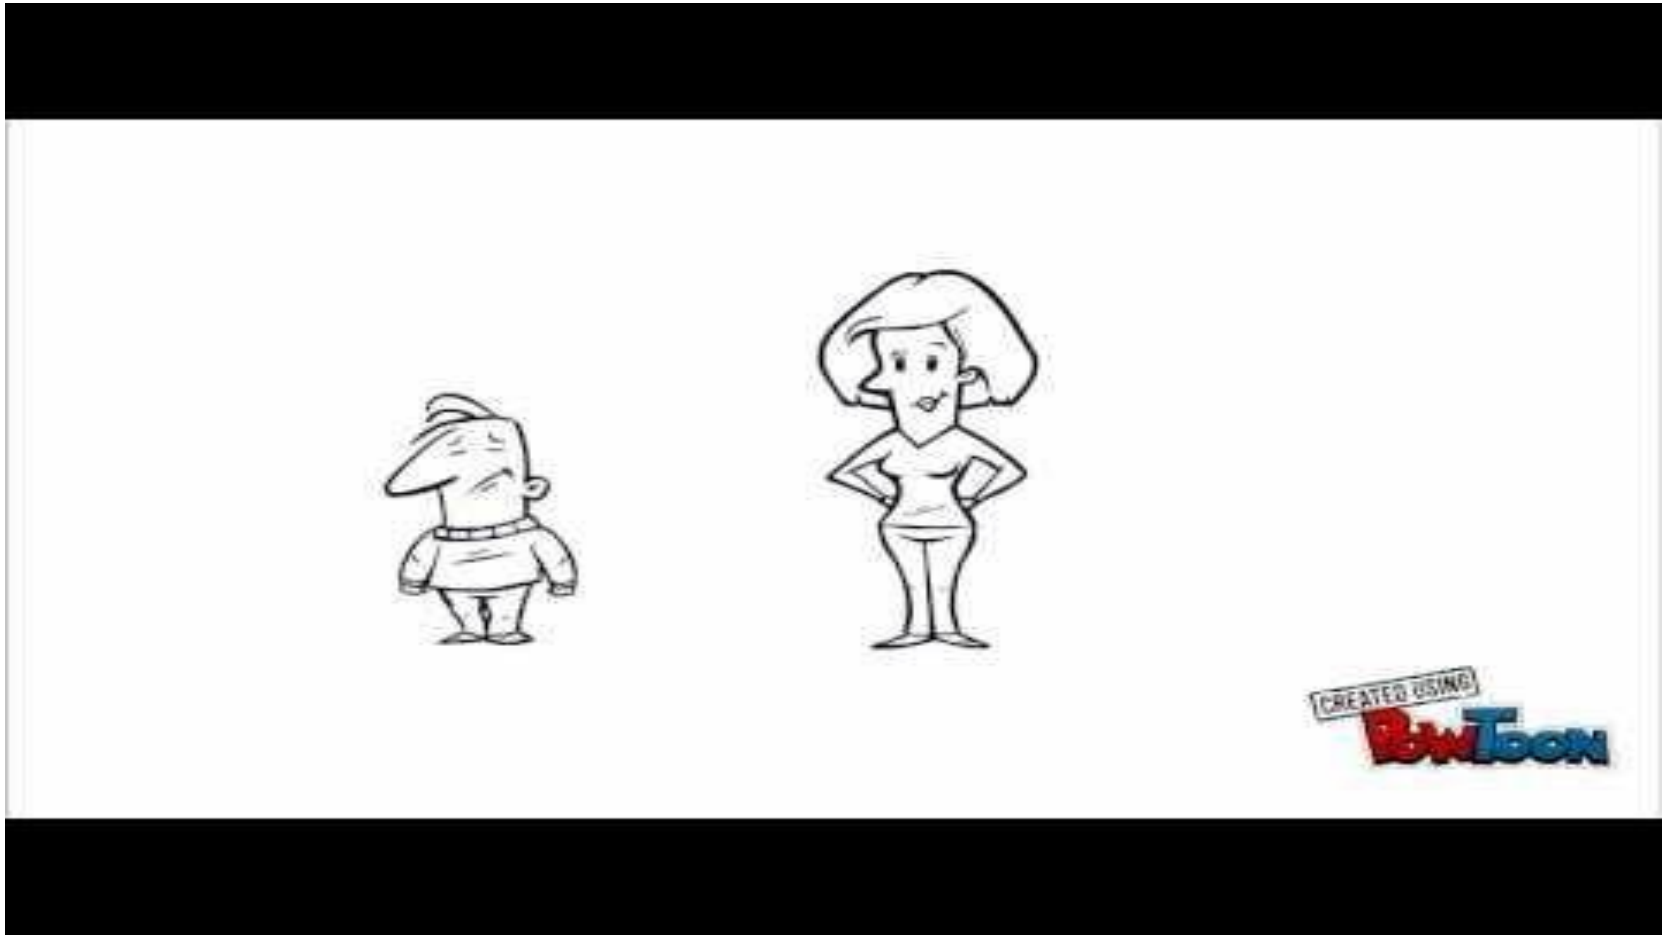

https://www.youtube.com/watch?v=K44x_VQmUs8

Algoritmo do Anel - LCR

Proposto por Le Lann, Chang e Roberts

Baseado na utilização de anel (físico ou lógico)

Não usa ficha!

Quando qualquer processo nota que o coordenador não está funcionando, monta uma mensagem ELEIÇÃO com seu próprio número (ex: PID+IP) e o envia a seu sucessor ou ao próximo que esteja em funcionamento

Algoritmo do Anel

Se o nó que recebe a mensagem de eleição tem um identificador maior que o informado na mensagem que recebeu, passa uma mensagem de eleição para seu vizinho da direita com seu próprio identificador.

Caso contrário aceita que o nó que tem o identificador contido na mensagem será o líder e repassa ao seu vizinho da direita.

Algoritmo do Anel

A eleição termina quando

Se o nó recebe uma mensagem com o identificador idêntico ao seu, ele se declara LÍDER

- envia essa mensagem pelo Anel

Este evento só ocorre quando a mensagem contendo o maior identificador circulou por todo o anel tornando todos os seus membros cientes do resultado.

Algoritmo de eleição por Anel

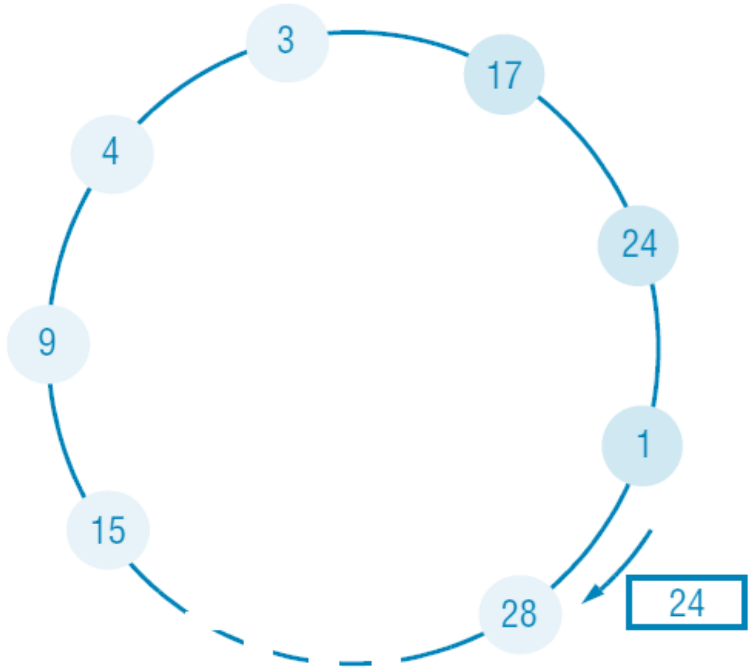

Note: The election was started by process 17. The highest process identifier encountered so far is 24. Participant processes are shown in a darker tint.

Tarefa 2

Existem tem processos P que a cada 30s imprimem o nome do coordenador

Vamos implementar um algoritmo de eleição que eleja qual será o coordenador

Vamos usar RMI na implementação

Crie uma Interface Remote chamada P com o método startElection() e setLeader()

Crie uma variável PID em cada processo

Use ManagementFactory.getRuntimeMXBean().getName()

In Java 9 the new process API can be used:

```
long pid = ProcessHandle.current().pid();
```

Tarefa 2

Fase de descoberta: Existem 3 instâncias de P que alguns instantes após as suas inicializações devem encontrar seus pares numa rede

- Usem o RMI Registry para tal
- Ao final da busca, cada P tem um Array com as 3 instâncias de P e seus respectivos PIDs

Em seguida, usando um algoritmo de eleição do Valentão, escolha qual deles é o coordenador

- Cada processo inicia uma eleição em um tempo aleatório (30s a 60s)
- Use os métodos setElection para comunicar a eleição e setLeader para se declarar como vencedores

Consenso Distribuído

Processos precisam ter uma visão idêntica (ou ação coordenada)

- Mesmo valor a ser dado a uma saída (output) do sistema
- Mesmo valor de uma variável compartilhada
- Mesmo estado ou ação do sistema (abortar, desligar)
- Definição de uma ordem total entre eventos (ou mensagens)

Esses processos estão distribuídos e podem falhar

Equivalência com outros problemas

- Acordo Bizantino
- Multicast Atômico

Modelo de Sistema

Modelo de Sistema:

- conjunto de processos Pi (i= 1,2,..,N)
- a comunicação por mensagem é confiável
- só os processos podem apresentar falhas

Tipos:

- falha de parada (crash)
- falta arbitrária (bizantina)

- É possível identificar o remetente de qualquer mensagem
  - Mensagens recebem uma assinatura digital para garantir a autenticidade do remetente
- Impede-se que processos faltosos possam falsificar identidade

Até f processos podem falhar simultaneamente do remetente

Problema do Consenso

Existem N processos, dos quais **f** processos podem falhar

- cada processo Pi propõe um único valor $vi \in D$
- todos os processos interagem entre si para a troca de valores
- em algum momento, os processos entram no estado “decided”, em que definem p valor da variável de decisão *di* , que depois disso não é mais modificada

O valor de **di** é sempre determinado em função dos valores vi fornecidos pelos N-f processos corretos.

Principais Requisitos

Terminação

- Em algum momento, cada processo correto atinge o estado “decided” e atribui um valor à variável de decisão di

Acordo

- todos os processos corretos atribuem o mesmo valor para a variável de decisão

Integridade

- se todos os processos corretos propuseram o mesmo valor vi =v, então qq processo correto no estado“decided” terá decidido di =v

Exemplo

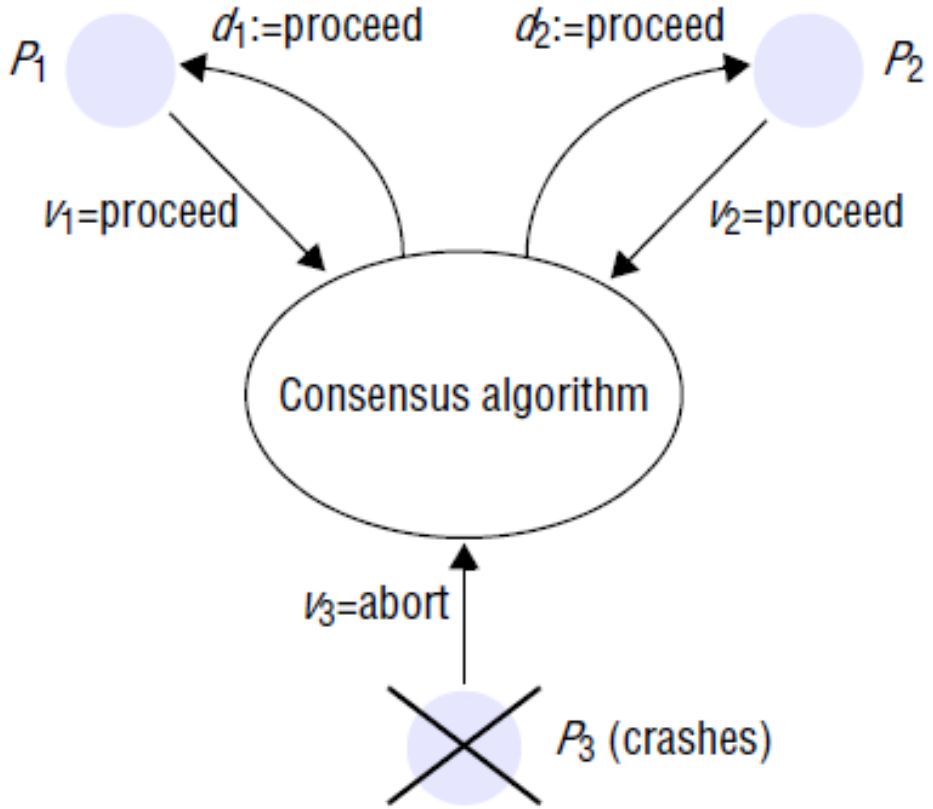
P_1
d_1:=proceed
d_2:=proceed
P_2
v_1=proceed
v_2=proceed
Consensus algorithm
v_3=abort
P_3 (crashes)

Relembrando

Sistemas Síncronos

VS

Sistemas Assíncronos

O Modelo Síncrono

Cada “passo de execução” em um processo demora entre [min, max]

- unidades de tempo
- A transmissão de qualquer mensagem demora um limite máximo de tempo
- O relógio local a cada processo tem uma defasagem limitada em relação ao relógio real

Tarefas (processos) têm tempos de processamento fixos e bem conhecidos

- controle de processos, processador paralelo

O Modelo Síncrono

A execução ocorre em rodadas de “processamento & comunicação” perfetamente sincronizadas

- O não-recebimento de uma mensagem em determinado período também traz informação!

Em sistemas reais, é difícil determinar estes limites de tempo. Mas este modelo é adequado quando a rede é dedicada...

Tarefa

Proponha uma solução de consenso distribuído:

1. Em um Modelo Síncrono
2. Suponha que não há falhas!

Exemplo de Consenso para Modelo Síncrono

```
Pseudo-código para nó i:
Init => {
        escolhe valor v;
        broadcast (v:i) para todos os vizinhos
        localset ← {(v:i)}
}
Enquanto (!terminou){ // Nova rodada
        recebe conjunto c de mensagens dos demais;
        diff  ← c - localset; // diferença entre conjuntos
        se diff ≠ ∅ {
                localset ← localset ∪ diff;
        } senão se (já recebeu de todos nós) {
                terminou ← true;
        }
}
d ← acha_mais_votado(localset);
imprime o valor de consenso d;
```

Propriedade

- Assumindo-se comunicação confiável e rede com N processos, após N-1 rodadas, um processo deverá ter recebido o valor de todos os nós ativos (não falhos).

Cada nó escolhe um valor $v \in [0, max]$ e difunde este valor para todos os demais nós na rede. Quando um nó tiver recebido o valor de todos os demais nós, escolhe o valor mais votado (ou no caso de empate, um valor default) como o valor de consenso d.

Análise

Terminação

- Como não há falhas todos os nós receberam as mensagens dos nós participantes do sistema
- Processos esperam até receber os valores de todos os outros

Acordo

- Processos usaram o valor mais votado do conjunto (que é o mesmo para todos)

Integridade

- As mensagens com os valores são entregues a todos os processos

Desafio dos dois generais

Consenso em Sistemas Assíncronos

Se processos podem ter falhas tipo crash (omissão), então a terminação não estará garantida, a menos que se detecte a falha.

Se o sistema é puramente assíncrono, pode ser impossível distinguir entre um crash de um processo e uma mensagem que demora um tempo indeterminado.

Fischer, Lynch & Paterson(*) apresentaram um resultado teórico fundamental:

- **é impossível** garantir consenso em um sistema puramente assíncrono com falhas tipo crash.

FLP Impossibiity Problem

Se processos podem apresentar falhas arbitrárias (bizantinas), então processos falhos podem comunicar valores aleatórios aos demais processos, evitando que os corretos tenham a mesma base de dados {v1,v2,..,vN}, para a tomada de uma decisão uniforme.

Fischer, Lynch, Paterson: Impossibility of Distributed Consensus with one faulty process, Journal of the ACM, v.32 (2), 1985.

Uma solução por consenso parcial

Algoritmos propostos por Lamport

- PAXOS (1989)
  - Difícil entendimento e implementação
- Multi-PAXOS

RAFT

- Maior simplicidade, uma forma de distribuir uma máquina de estado em um sistemas distribuído
- Diego Ongaro PHD (2015)
- Understandablity first!

Serviços de consenso

- Raft é usado em HydraBase (Facebook), Rafter/Basho (NOSQL keyvalue store), ZooKeeper, RAMCloud

RAFT Overview

É tarefa do algoritmo de consenso manter os logs replicados consistentes.

- Líder forte (as entradas do log sempre fluem do lider para os membros)
- mais eficiente do que soluções leader-less e mais simples: operação noranal ou leader election

Para eleição de líder, usa temporizadores randômicos, para evitar “race condition” na eleição

Simplicidade

- decompõe o problema em eleição de lider, replicação do log e segurança

Raft User Study

QUIZ GRADES

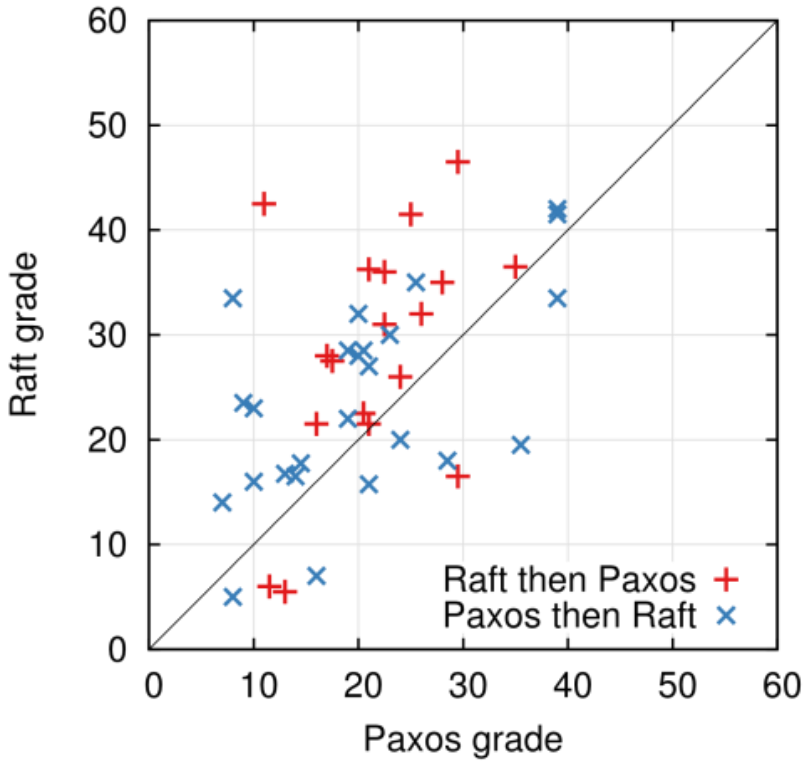

SURVEY RESULTS

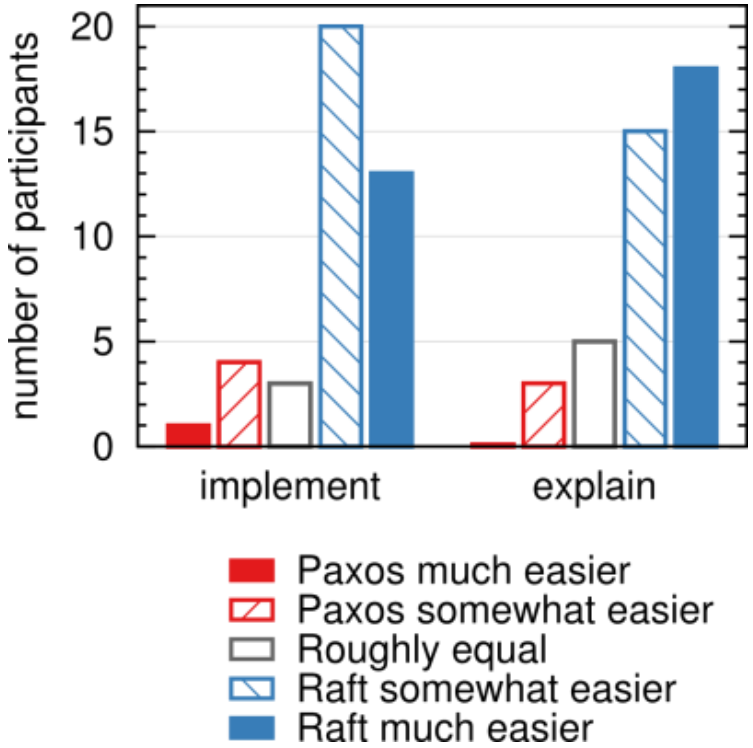

RAFT

Diego Ongaro and John Ousterhout. In Search of an Understandable Consensus Algorithm. 2014,, Stanford University

- https://www.usenix.org/conference/atc14/technical-sessions/presentation/ongaro

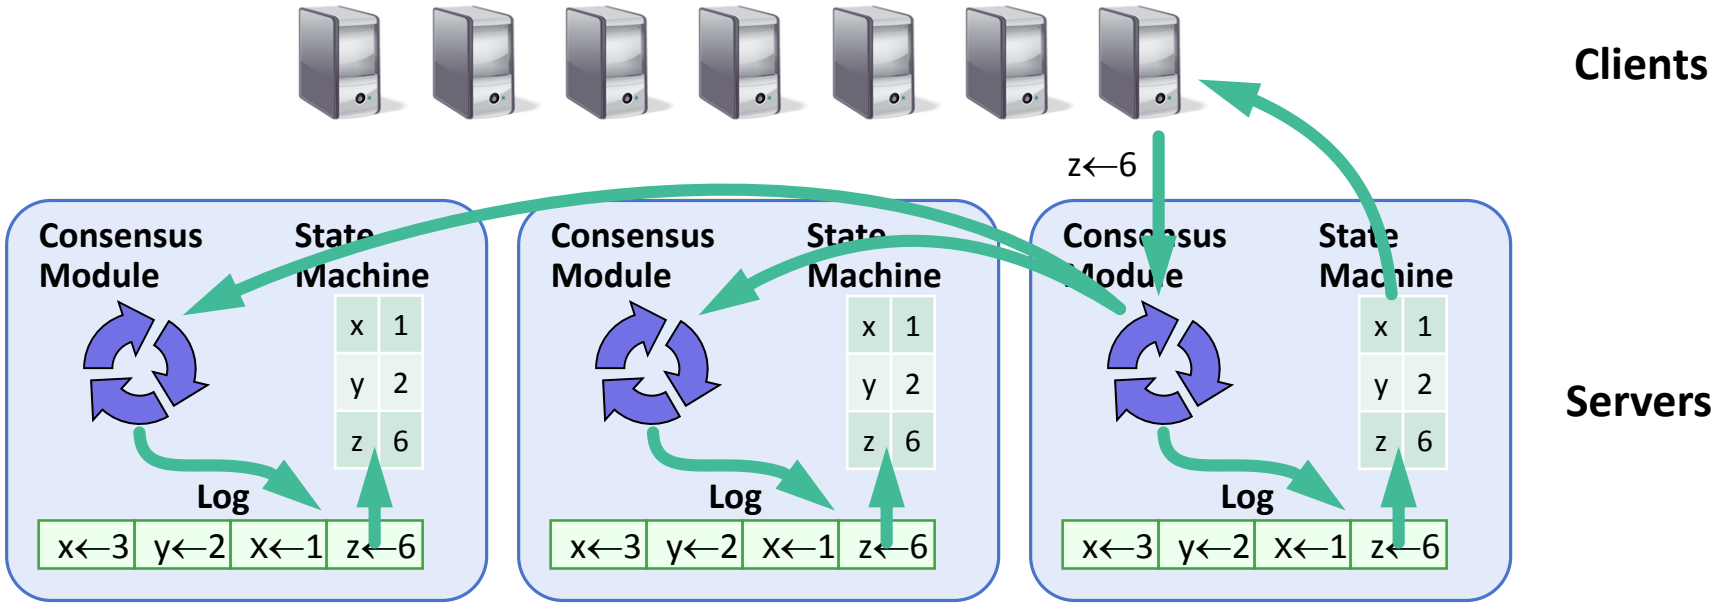

RAFT Overview

1. Leader election
   - Select one of the servers to act as cluster leader
   - Detect crashes, choose new leader
2. Log replication (normal operation)
   - Leader takes commands from clients, appends them to its log
   - Leader replicates its log to other servers (overwriting inconsistencies)
3. Safety
   - Only a server with an up-to-date log can become leader

RAFT Overview

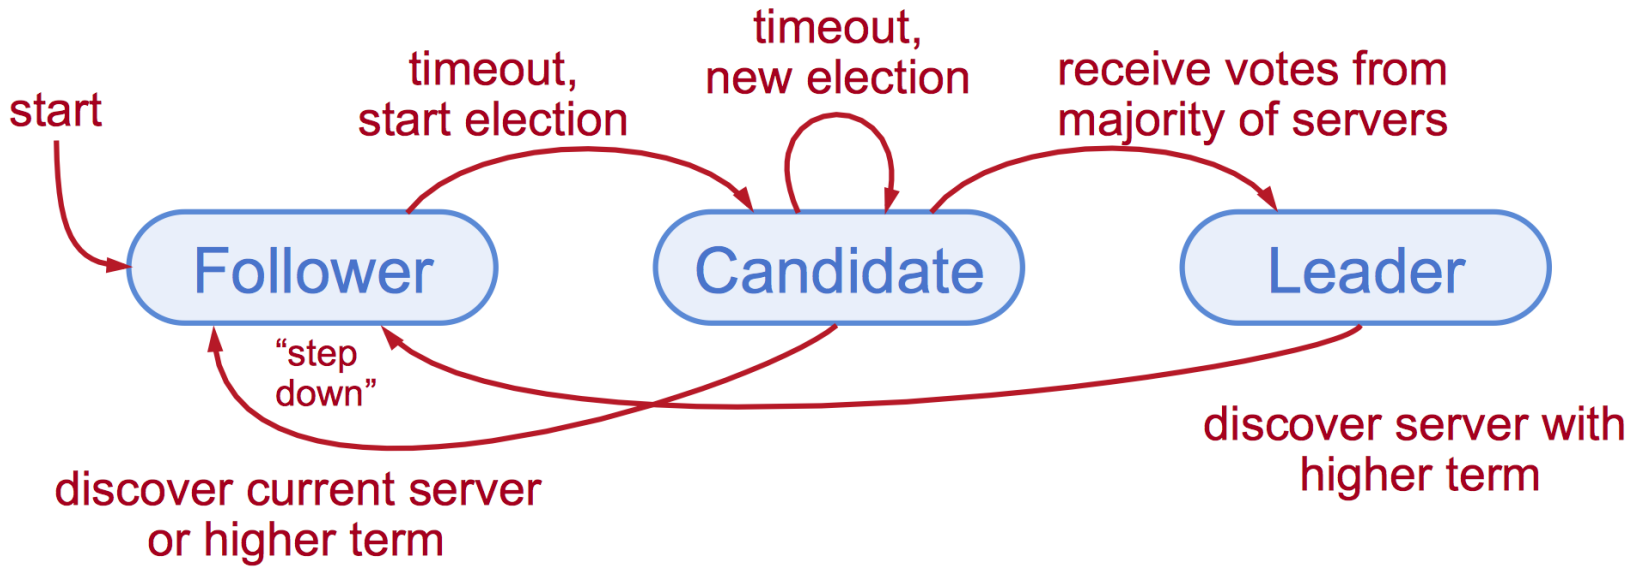

Candidatos tentam se eleger como líder, e acabam competindo entre si

Sempre existe no máximo um líder, e todos os demais nós são followers ou candidatos.

O líder responde a todas as requisições de clientes e os followers são passivos (só respondem requisições do líder}.

Tempo dividido em Termos

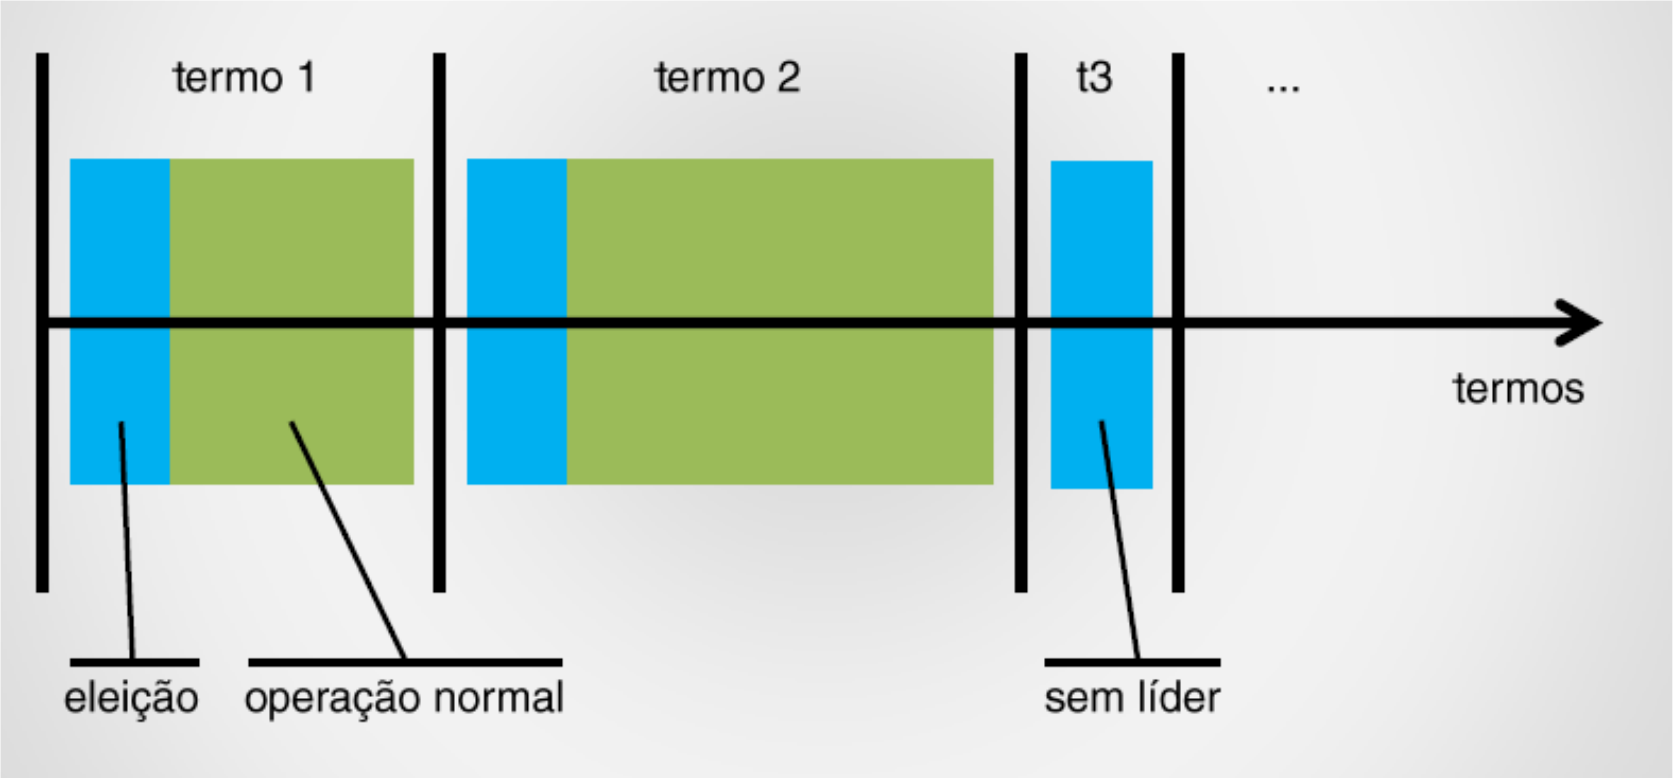

Explicação Visual

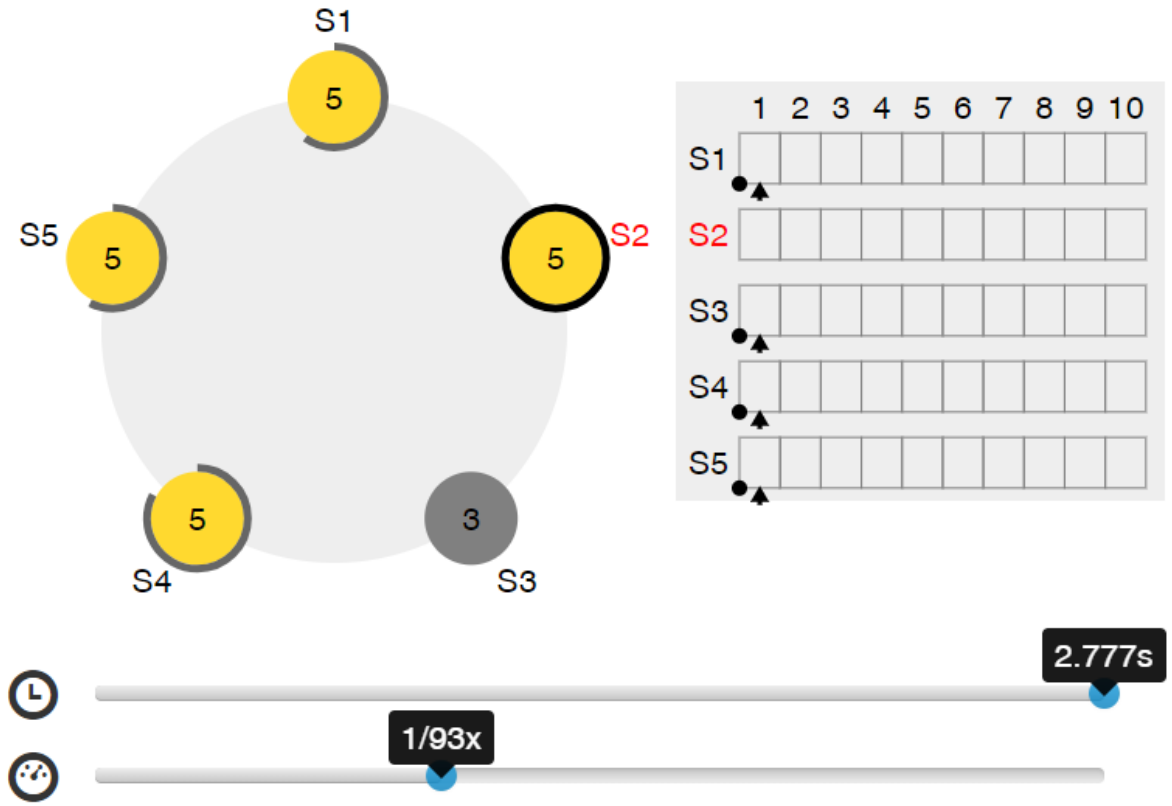

https://raft.github.io/

Dúvidas?